Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Южно-Уральский государственный университет
(национальный исследовательский университет)»
Институт естественных и точных наук

Отчет
Лабораторная работа №2.
Методы численной оптимизации.

Выполнил: студент группы ЕТ-310
Тельнов С.М.
Проверил: преподаватель кафедры ВМ
Стариков Я.Е.

Челябинск — 2026

Краткое содержание

- Теоретическая часть 3
- Практическая часть 8
- Вывод 17

Теоретическая часть

1. Постановка задачи и структура программного комплекса

Решается задача безусловной минимизации скалярной функции $f : \mathbb{R}^n \to \mathbb{R}$:

$$\vec{\theta}^* = \arg\min_{\vec{\theta}} f(\vec{\theta}),$$

а также задача с ограничениями типа равенств и неравенств (блок 5). Все методы реализованы на языке Python (среда управления зависимостями `uv`, библиотеки `numpy` и `matplotlib`, линтер `ruff`) и разбиты на модули:

- `objectives.py` — целевые функции и численное дифференцирование;
- `optimizers.py` — градиентные методы первого и второго порядка, одномерный поиск шага;
- `zeroth_order.py` — методы нулевого порядка (Нелдер–Мид, рой частиц);
- `least_squares.py` — нелинейный метод наименьших квадратов;
- `session_task.py` — прикладная задача с ограничениями, мультизапуск и кластеризация;
- `main.py` — запуск пяти блоков расчётов и построение всех графиков.

Ключевые классы и их назначение:
Класс `TargetFunction` (файл `objectives.py`) — базовый класс скалярной целевой функции. Хранит ссылку на функцию $f(\vec{\theta})$, а также аналитические градиент и гессиан, заданные при создании. При отсутствии аналитических выражений методы `grad` и `hess` автоматически переходят на численные оценки: градиент вычисляется центральными конечными разностями

$$\frac{\partial f}{\partial \theta_i}(\vec{\theta}) \approx \frac{f(\vec{\theta} + h\vec{e}_i) - f(\vec{\theta} - h\vec{e}_i)}{2h}, \qquad h = 10^{-5},$$

а численный гессиан получается как якобиан численного градиента (вспомогательная функция `jacobian`, $h = 10^{-4}$). Класс также хранит начальную точку $\vec{\theta}^0$ и параметры области построения изолиний. От него наследуются:

- `Rosenbrock(n)` — функция Розенброка $f(\vec{\theta}) = \sum_{i=1}^{n-1} \left[100\,(\theta_{i+1} - \theta_i^2)^2 + (1 - \theta_i)^2\right]$ с единственным минимумом $f^* = 0$ в точке $(1, \ldots, 1)^T$;
- `Himmelblau` — функция Химмельблау $f(\vec{\theta}) = (\theta_1^2 + \theta_2 - 11)^2 + (\theta_1 + \theta_2^2 - 7)^2$ с четырьмя минимумами;
- `ExamSession` — целевая функция прикладной задачи распределения времени (блок 5).

Класс `LineSearch` (файл `optimizers.py`) — одномерная минимизация шага α вдоль луча $\vec{\theta} + \alpha\vec{d}$ методом золотого сечения. Интервал неопределённости сначала расширяется вдвое, пока значение $\varphi(\alpha) = f(\vec{\theta} + \alpha\vec{d})$ убывает, затем сжимается с коэффициентом $r = \frac{3-\sqrt{5}}{2} \approx 0{,}618$ до достижения точности 10^{-8}.
Класс `Optimizer` — базовый класс итерационного метода спуска. Его метод `run` реализует общий цикл: вычисление градиента, проверку критерия остановки $\|\nabla f\| < \texttt{tol}$, выполнение шага через абстрактный метод `_move` и запись истории. После завершения доступны история приближений `history_`, значения функции `f_history_` и нормы градиента `grad_norms_`. Конкретный алгоритм задаётся переопределением `_move`, сброс внутреннего состояния — переопределением `_reset`. От этого класса наследуются все градиентные методы (`SteepestDescent`, `CoordinateDescent`, `NesterovMomentum`, `Adam`, `Adagrad`, `RMSProp`, `Newton`, `BFGS`), что позволяет единообразно сравнивать их траектории.
Классы нулевого порядка (файл `zeroth_order.py`): `NelderMead` — симплекс-метод с сохранением истории вершин симплекса; `PSO` — метод роя частиц с сохранением снимков позиций и скоростей частиц на каждой итерации.
Класс `LeastSquaresProblem` (файл `least_squares.py`) — постановка задачи МНК: хранит векторную функцию невязок $\vec{r}(\vec{\theta})$, её якобиан J (аналитический или конечные разности), целевую функцию $S(\vec{\theta}) = \vec{r}^{\,T}\vec{r}$ и градиент $\nabla S = J^T\vec{r}$.

2. Градиентные методы первого порядка

Все методы блока используют только значения функции и её первых производных. Градиент вычисляется двумя способами — аналитически и численно (центральные разности), что позволяет проверить корректность реализации дифференцирования.
Наискорейший градиентный спуск (`SteepestDescent`). Итерация:

$$\vec{\theta}^{\,k+1} = \vec{\theta}^{\,k} - \alpha_k \nabla f(\vec{\theta}^{\,k}), \qquad \alpha_k = \arg\min_{\alpha \geq 0} f\big(\vec{\theta}^{\,k} - \alpha \nabla f(\vec{\theta}^{\,k})\big),$$

где одномерный минимум находится классом `LineSearch` (золотое сечение). Если задан параметр `lr`, одномерный поиск отключается и выполняется спуск с фиксированным множителем lr:

$$\vec{\theta}^{\,k+1} = \vec{\theta}^{\,k} - \mathrm{lr}\,\nabla f(\vec{\theta}^{\,k}).$$

Такой вариант дешевле по числу вычислений f, но шаг должен удовлетворять условию устойчивости $\mathrm{lr} < 2/L$ (L — константа Липшица градиента), поэтому на плохо обусловленных функциях он либо расходится, либо сходится медленно. В расчётах $\mathrm{lr} = 2 \cdot 10^{-3}$.
Покомпонентный спуск (`CoordinateDescent`). Координаты обновляются по одной в цикле Гаусса–Зейделя, причём градиент пересчитывается после каждого шага компоненты:

$$\theta_i \leftarrow \theta_i - \alpha_i \frac{\partial f}{\partial \theta_i}(\vec{\theta}), \qquad \alpha_i = \arg\min_{\alpha \geq 0} f\big(\vec{\theta} - \alpha\, \mathrm{grad}_i f(\vec{\theta})\, \vec{e}_i\big).$$

Реализованы два варианта обхода осей: последовательный ($\theta_1 \to \theta_2 \to \dots$) и со случайным перемешиванием порядка координат на каждой итерации (`shuffle=True`, генератор с фиксированным зерном). Как и у наискорейшего

спуска, при заданном `lr` одномерный поиск заменяется фиксированным шагом $\theta_i \leftarrow \theta_i - \mathrm{lr}\,\partial f/\partial\theta_i$ с тем же $\mathrm{lr} = 2 \cdot 10^{-3}$.

Метод Нестерова (`NesterovMomentum`) — спуск с ускорением, градиент вычисляется в опережающей (look-ahead) точке:

$$\vec{v}^{\,k+1} = \mu\,\vec{v}^{\,k} - \mathrm{lr}\,\nabla f(\vec{\theta}^{\,k} + \mu\,\vec{v}^{\,k}), \qquad \vec{\theta}^{\,k+1} = \vec{\theta}^{\,k} + \vec{v}^{\,k+1},$$

параметры: $\mu = 0{,}95$, $\mathrm{lr} = 10^{-3}$.

Метод Adam (`Adam`) — адаптивный шаг с экспоненциальными скользящими средними градиента и его квадрата:

$$\vec{m}_t = \beta_1\vec{m}_{t-1} + (1-\beta_1)\,\nabla f_t, \qquad \vec{v}_t = \beta_2\vec{v}_{t-1} + (1-\beta_2)\,(\nabla f_t)^2,$$

с поправками на смещение $\hat{\vec{m}}_t = \vec{m}_t/(1-\beta_1^t)$, $\hat{\vec{v}}_t = \vec{v}_t/(1-\beta_2^t)$ и шагом

$$\vec{\theta}^{\,t+1} = \vec{\theta}^{\,t} - \mathrm{lr}\,\frac{\hat{\vec{m}}_t}{\sqrt{\hat{\vec{v}}_t} + \varepsilon}, \qquad \beta_1 = 0{,}9,\ \beta_2 = 0{,}999,\ \varepsilon = 10^{-8},\ \mathrm{lr} = 0{,}05.$$

Метод Adagrad (`Adagrad`) — адаптивный шаг с накапливаемой суммой квадратов компонент градиента:

$$\vec{G}_t = \vec{G}_{t-1} + (\nabla f_t)^2, \qquad \vec{\theta}^{\,t+1} = \vec{\theta}^{\,t} - \mathrm{lr}\,\frac{\nabla f_t}{\sqrt{\vec{G}_t} + \varepsilon},$$

все операции покомпонентные, $\mathrm{lr} = 1$, $\varepsilon = 10^{-8}$. Редко обновляемые координаты получают больший шаг, но монотонный рост $\vec{G}_t$ постепенно глушит шаг по всем координатам.

Метод RMSProp (`RMSProp`) снимает проблему затухания шага, заменяя накапливаемую сумму экспоненциальным скользящим средним:

$$\vec{v}_t = \beta\,\vec{v}_{t-1} + (1-\beta)\,(\nabla f_t)^2, \qquad \vec{\theta}^{\,t+1} = \vec{\theta}^{\,t} - \mathrm{lr}\,\frac{\nabla f_t}{\sqrt{\vec{v}_t} + \varepsilon},$$

$\beta = 0{,}999$, $\mathrm{lr} = 0{,}01$, $\varepsilon = 10^{-8}$. Окно усреднения ограничено, поэтому шаг не стремится к нулю; при постоянном lr вблизи минимума (где $\vec{v}_t \approx (\nabla f_t)^2$) итерации превращаются в блуждание с амплитудой $\sim \mathrm{lr}$.

3. Методы второго порядка

Классический метод Ньютона (`Newton`):

$$\vec{\theta}^{\,k+1} = \vec{\theta}^{\,k} - H_f^{-1}(\vec{\theta}^{\,k})\,\nabla f(\vec{\theta}^{\,k}).$$

Гессиан вычисляется аналитически либо численно. Система решается методом наименьших квадратов (`lstsq`); если направление не является направлением спуска ($\nabla f^T\vec{p} \geq 0$) или вырождено, выполняется откат на антиградиент, а если полный шаг не уменьшает функцию — одномерный поиск вдоль направления Ньютона.

Квазиньютоновский метод BFGS (`BFGS`) обходится без точного гессиана, итерационно аппроксимируя обратный гессиан $B_k \approx H_k^{-1}$ поправкой ранга два:

$$\vec{s}_k = \vec{\theta}^{\,k+1} - \vec{\theta}^{\,k} = \alpha_k\vec{p}_k, \qquad \vec{y}_k = \nabla f(\vec{\theta}^{\,k+1}) - \nabla f(\vec{\theta}^{\,k}), \qquad \rho_k = \frac{1}{\vec{y}_k^{\,T}\vec{s}_k},$$

$$B_{k+1} = (I - \rho_k\,\vec{s}_k\vec{y}_k^{\,T})\,B_k\,(I - \rho_k\,\vec{y}_k\vec{s}_k^{\,T}) + \rho_k\,\vec{s}_k\vec{s}_k^{\,T},$$

направление спуска $\vec{p}_k = -B_k\nabla f(\vec{\theta}^{\,k})$, шаг α_k подбирается `LineSearch`; при нарушении положительной определённости матрица сбрасывается в единичную.

4. Методы нулевого порядка

Метод Нелдера–Мида (`NelderMead`). В n-мерном пространстве строится симплекс из $n+1$ вершины $\{\vec{x}_1, \dots, \vec{x}_{n+1}\}$; вершины сортируются по значениям f, отражение выполняется наихудшей вершины через центроид $\vec{x}_o$ лучших n вершин, $\vec{x}_r = \vec{x}_o + \alpha(\vec{x}_o - \vec{x}_{n+1})$, $\alpha = 1$. Далее применяются стандартные операции с коэффициентами $\gamma = 2$ (растяжение $\vec{x}_e = \vec{x}_o + \gamma(\vec{x}_r - \vec{x}_o)$), $\rho = 0{,}5$ (внешнее и внутреннее сжатие) и $\sigma = 0{,}5$ (редукция — стягивание всех вершин к лучшей). Критерий останова — разброс расстояний вершин до центроида:

$$\max_i \|\vec{x}_i - \vec{x}_c\| < \varepsilon, \qquad \vec{x}_c = \frac{1}{n+1}\sum_i \vec{x}_i.$$

Метод роя частиц (PSO) (`PSO`). Скорость и позиция j-й частицы обновляются по схеме

$$\vec{v}_j \leftarrow \omega_k\,\vec{v}_j + c_{1k}\,r_1 \odot (\vec{p}_j^{\,best} - \vec{x}_j) + c_{2k}\,r_2 \odot (\vec{g}^{\,best} - \vec{x}_j), \qquad \vec{x}_j \leftarrow \vec{x}_j + \vec{v}_j,$$

где $r_1, r_2 \sim U(0,1)$. Реализована модифицированная схема с адаптивными коэффициентами: инерция линейно убывает $\omega_k = \omega_{max} - (\omega_{max} - \omega_{min})\,k/k_{max}$, $\omega_{max} = 0{,}9$, $\omega_{min} = 0{,}4$; когнитивный и социальный веса каждой частицы зависят от отставания её локального рекорда F^{LB} от глобального F^{GB}:

$$c_{1k} = c_{min} + (c_{max} - c_{min})\,\gamma_k, \qquad c_{2k} = c_{max} - (c_{max} - c_{min})\,\gamma_k, \qquad \gamma_k = \frac{F^{LB} - F^{GB}}{\max_j (F_j^{LB} - F^{GB}}$$

то есть отставая от лидера роя, частица сильнее опирается на собственный рекорд, а приближаясь к нему — на социальную тягу ($c_{min} = 0{,}5$, $c_{max} = 2{,}5$).

5. Нелинейный метод наименьших квадратов

Задача ставится как минимизация суммы квадратов невязок $S(\vec{\theta}) = \|\vec{r}(\vec{\theta})\|^2$ с градиентом $\nabla S = J^T \vec{r}$.

Метод Гаусса–Ньютона (`GaussNewton`) аппроксимирует гессиан $H \approx J^T J$ и решает на каждой итерации систему

$$(J^T J)\,\vec{h} = -J^T \vec{r},$$

при необходимости дробя шаг вдвое до убывания невязки.

Метод Левенберга–Марквардта (`LevenbergMarquardt`) добавляет адаптивное демпфирование:

$$\left(J^T J + \lambda\ \mathrm{diag}(J^T J)\right)\vec{h}_{lm} = -J^T \vec{r}.$$

Качество шага оценивается метрикой выигрыша

$$\rho(\vec{h}_{lm}) = \frac{S(\vec{\theta}) - S(\vec{\theta} + \vec{h}_{lm})}{\vec{h}_{lm}^{\,T} J^T J\,\vec{h}_{lm} + 2\lambda\,\vec{h}_{lm}^{\,T}\,\mathrm{diag}(J^T J)\,\vec{h}_{lm}};$$

при $\rho > 0$ шаг принимается и λ уменьшается в ν раз, иначе λ увеличивается в ν раз и шаг пересчитывается ($\nu = 10$).

6. Прикладная задача с ограничениями: распределение времени на сессию

Максимизируется суммарная вероятность сдачи $N = 3$ экзаменов при бюджете времени $M = 8$ ч:

$$\max_{\vec{t}} \sum_{i=1}^{3} P_i(t_i) \quad \text{при} \quad \sum_{i=1}^{3} t_i \le M,\ \ t_i > 0,$$

что сводится к минимизации $f(\vec{t}) = -\sum_i P_i(t_i)$. Первые два экзамена моделируются логистическими кривыми $P_i(t) = 1/(1 + e^{-k_i(t - t_{0i})})$ с параметрами $(k_1, t_{01}) = (1{,}5;\ 3{,}0)$, $(k_2, t_{02}) = (2{,}0;\ 4{,}5)$, третий — функцией типа Гаусса $P_3(t) = \exp(-(t-2)^2/1{,}5)$.
Ограничения учитываются двумя способами.
Проекция на допустимое множество (класс `ProjectedGradient`): шаг градиентного спуска с `LineSearch` чередуется с евклидовой проекцией на симплекс $\{\vec{t} \ge 0 : \sum_i t_i = M\}$ (функция `project_simplex`); при необходимости шаг дробится до убывания f. Остановка — по невязке условий Куна–Таккера $\|\vec{x} - \Pi(\vec{x} - \nabla f)\| < \varepsilon$.
Метод штрафных функций (класс `QuadraticPenalty`): минимизация $F_\mu(\vec{t}) = f(\vec{t}) + \mu\, h(\vec{t})$ методом BFGS с квадратичным штрафом

$$h(\vec{t}) = \sum_{i=1}^{N} \max^2(0, -t_i) + \max^2\Big(0, \sum_{i=1}^{N} t_i - M\Big),$$

параметр μ наращивается по схеме $10 \to 100 \to 1000$.
Для анализа устойчивости выполняется серия из 100 запусков обоих подходов со случайных начальных приближений $t_i \sim U(0{,}1;\ M)$; сошедшиеся решения группируются в кластеры округлением координат до двух знаков, для каждого кластера вычисляются средняя точка, число траекторий и значение f.

Практическая часть

Все расчёты выполняются одной командой `python main.py`, которая последовательно запускает пять блоков и сохраняет графики в файлы `png`. Для каждого метода фиксируется траектория приближений и печатается сводка: число итераций, точка окончания и значение функции.

1. Градиентные методы первого порядка

Методы тестируются на двумерных функциях Розенброка (старт $(-1{,}5;\ 2{,}0)$) и Химмельблау (старт $(-4;\ 4)$); каждый метод прогоняется с аналитическим и численным градиентом. Результаты сведены в таблицы 1 и 2, траектории показаны на рис. 1 и 2.

Таблица 1. Сходимость методов первого порядка на функции Розенброка

Метод	Градиент	Итераций	$f(\vec{\theta}^*)$	$\vec{\theta}^*$
Наискорейший спуск	аналит.	18761	$6.4 \cdot 10^{-11}$	$(1.00001;\ 1.00002)$
	численный	16369	$1.2 \cdot 10^{-10}$	$(1.00001;\ 1.00002)$
Градиентный спуск (фикс. шаг)	аналит.	10027	$1.2 \cdot 10^{-10}$	$(0.99999;\ 0.99998)$
	численный	10002	$1.3 \cdot 10^{-10}$	$(0.99999;\ 0.99998)$
Покомпонентный ($x \to y$)	аналит.	9804	$2.5 \cdot 10^{-11}$	$(1.00000;\ 1.00001)$
	численный	9806	$2.5 \cdot 10^{-11}$	$(1.00000;\ 1.00001)$
Покомпонентный (перемеш.)	аналит.	12318	$9.8 \cdot 10^{-11}$	$(1.00001;\ 1.00002)$
	численный	12282	$1.0 \cdot 10^{-10}$	$(1.00001;\ 1.00002)$
Покомпонентный (фикс. шаг)	аналит.	18486	$1.2 \cdot 10^{-10}$	$(0.99999;\ 0.99998)$
	численный	18486	$1.2 \cdot 10^{-10}$	$(0.99999;\ 0.99998)$
Момент Нестерова	аналит.	1176	$1.2 \cdot 10^{-10}$	$(0.99999;\ 0.99998)$
	численный	1176	$1.2 \cdot 10^{-10}$	$(0.99999;\ 0.99998)$
Adam	аналит.	1840	$9.5 \cdot 10^{-11}$	$(1.00000;\ 0.99998)$
	численный	1840	$9.6 \cdot 10^{-11}$	$(1.00000;\ 0.99998)$
Adagrad	аналит.	19863	$1.2 \cdot 10^{-10}$	$(0.99999;\ 0.99998)$
	численный	19863	$1.2 \cdot 10^{-10}$	$(0.99999;\ 0.99998)$
RMSProp	аналит.	20000	$2.2 \cdot 10^{-2}$	$(0.990;\ 0.966)$
	численный	20000	$2.2 \cdot 10^{-2}$	$(0.980;\ 0.976)$

Таблица 2. Сходимость методов первого порядка на функции Химмельблау

Метод	Градиент	Итераций	$f(\vec{\theta}^*)$	$\vec{\theta}^*$
Наискорейший спуск	аналит.	27	$4.1 \cdot 10^{-13}$	$(3.584;\ -1.848)$
	численный	27	$4.1 \cdot 10^{-13}$	$(3.584;\ -1.848)$
Градиентный спуск (фикс. шаг)	аналит.	111	$6.3 \cdot 10^{-13}$	$(-2.805;\ 3.131)$
	численный	111	$6.3 \cdot 10^{-13}$	$(-2.805;\ 3.131)$
Покомпонентный ($x \to y$)	аналит.	16	$1.5 \cdot 10^{-14}$	$(-3.779;\ -3.283)$
	численный	16	$1.5 \cdot 10^{-14}$	$(-3.779;\ -3.283)$
Покомпонентный (перемеш.)	аналит.	20	$1.9 \cdot 10^{-13}$	$(-3.779;\ -3.283)$
	численный	18	$1.9 \cdot 10^{-13}$	$(-3.779;\ -3.283)$
Покомпонентный (фикс. шаг)	аналит.	222	$6.3 \cdot 10^{-13}$	$(-2.805;\ 3.131)$
	численный	222	$6.3 \cdot 10^{-13}$	$(-2.805;\ 3.131)$
Момент Нестерова	аналит.	241	$2.5 \cdot 10^{-13}$	$(-2.805;\ 3.131)$
	численный	241	$2.5 \cdot 10^{-13}$	$(-2.805;\ 3.131)$
Adam	аналит.	290	$2.7 \cdot 10^{-13}$	$(-2.805;\ 3.131)$
	численный	290	$2.7 \cdot 10^{-13}$	$(-2.805;\ 3.131)$
Adagrad	аналит.	23	$2.4 \cdot 10^{-13}$	$(-2.805;\ 3.131)$
	численный	23	$2.4 \cdot 10^{-13}$	$(-2.805;\ 3.131)$
RMSProp	аналит.	133	$6.2 \cdot 10^{-13}$	$(-2.805;\ 3.131)$
	численный	133	$6.2 \cdot 10^{-13}$	$(-2.805;\ 3.131)$

На функции Розенброка (рис. 1) все методы, кроме RMSProp, достигают глобального минимума $(1; 1)$ с точностью не хуже 10^{-10}. Наискорейший спуск из-за точного одномерного поиска делает характерные зигзагообразные микродвижения по дну изогнутой долины и требует больше всего итераций (более 18 тысяч). Его вариант с фиксированным шагом $\text{lr} = 2 \cdot 10^{-3}$ сходится почти вдвое быстрее (10 тысяч итераций) и осцилляции у дна долины затухают, что видно на траектории: шаг, безопасный для всей траектории ($L \approx 10^3$ в долине), заметно консервативнее одномерного поиска, зато не требует дополнительных вычислений f.
Покомпонентный спуск движется ломаной с прямыми участками вдоль осей (видны оба варианта обхода); его вариант с фиксированным шагом ведёт себя аналогично градиентному, но в полтора раза медленнее из-за покомпонентного характера движения. Момент Нестерова и Adam, использующие накопленную «инерцию» и адаптивный шаг, проходят долину уверенно и сходятся на порядок быстрее. Adagrad также достигает минимума, однако монотонно растущая сумма G_t постепенно глушит шаг, и метод по числу итераций догоняет наискорейший спуск. RMSProp со скользящим средним удерживает рабочий размер шага и быстро спускается в долину, но в её дне, где $\vec{v}_t \approx (\nabla f_t)^2$, итерации вырождаются в блуждание с амплитудой $\sim \text{lr}$ вокруг минимума: за 20 тысяч итераций точность по норме градиента 10^{-5} не достигается ($f \approx 2.2 \cdot 10^{-2}$). Это ожидаемое поведение постоянношаговой версии метода на изогнутой долине. Численный градиент даёт траектории, практически неотличимые от аналитического, что подтверждает корректность конечно-разностной схемы.
На функции Химмельблау (рис. 2) из точки $(-4; 4)$ разные методы сходятся к разным минимумам, что наглядно демонстрирует многомодальность функции: наискорейший спуск за 27 итераций приходит в $(3.584;\ -1.848)$, оба покомпонентных метода со случайным и последовательным обходом движутся ломаными вдоль осей и завершаются в $(-3.779;\ -3.283)$, метод Нестерова, Adam, Adagrad, RMSProp и оба спуска с фиксированным шагом приходят в минимум

$(-2.805;\ 3.131)$, попадая в его бассейн притяжения. Adagrad оказывается быстрее всех (23 итерации) — на хорошо обусловленных участках его затухающий шаг после первых резких шагов точно доводит траекторию до минимума; спуски с фиксированным шагом сходятся устойчиво, но уступают в числе итераций. Заметим, что методы с фиксированным шагом (Нестеров, Adam, Adagrad, RMSProp и оба спуска с фиксированным множителем) ведут себя стабильно на многомодальной функции, тогда как на унимодальной Розенброке чувствительность к выбору lr проявляется сильнее.

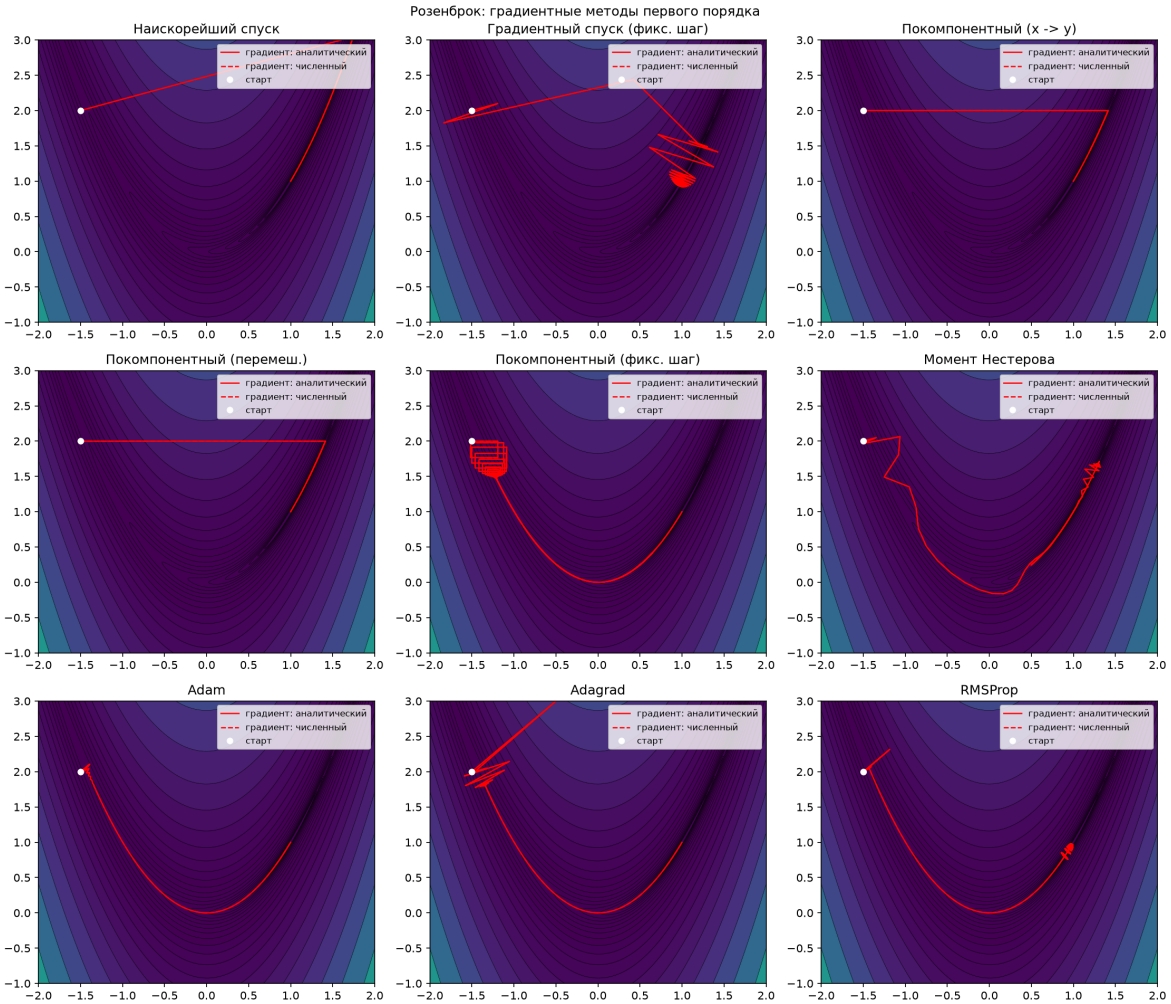


Рис. 1. Траектории методов первого порядка на функции Розенброка

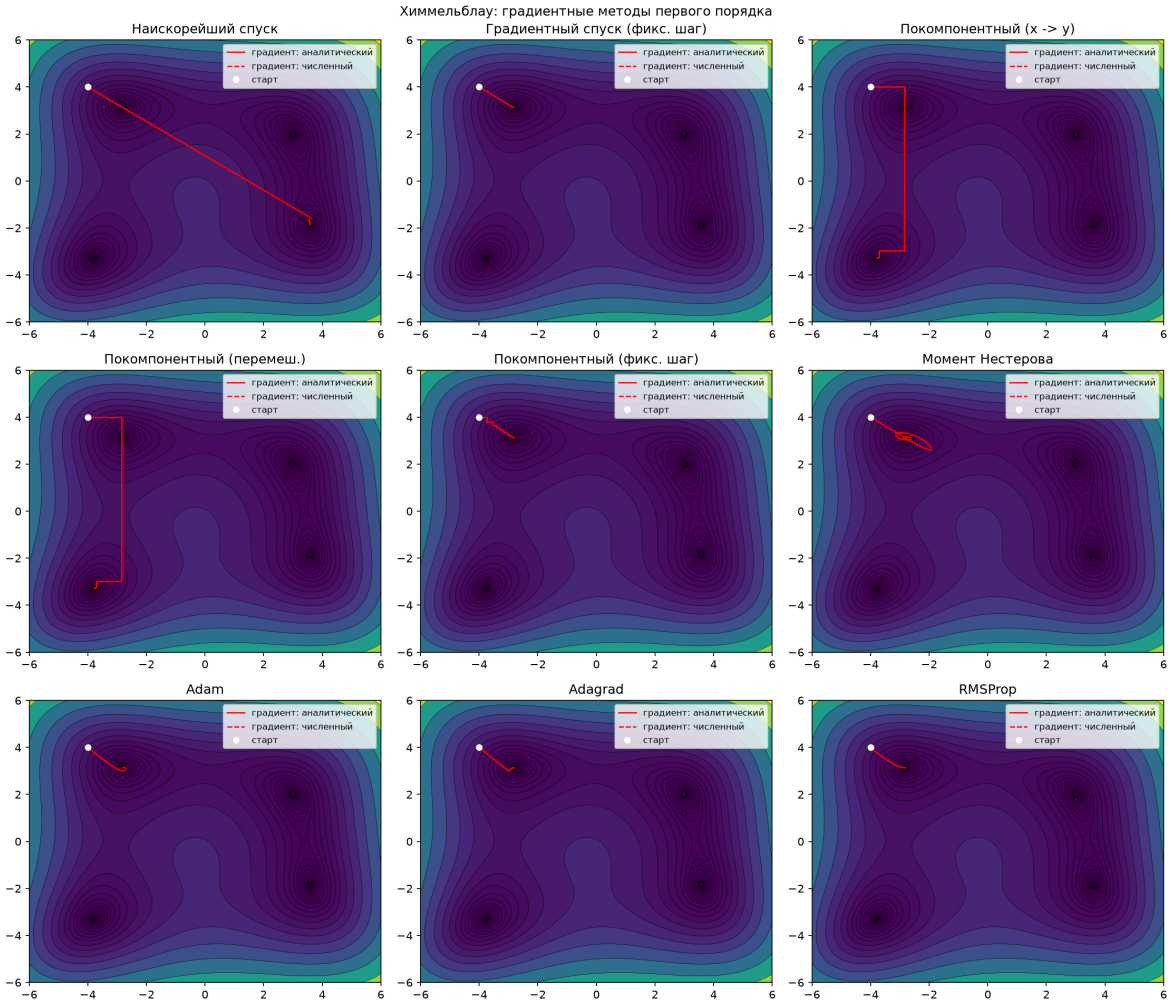


Рис. 2. Траектории методов первого порядка на функции Химмельблау

2. Методы второго порядка

Метод Ньютона прогоняется с аналитическим и численным гессианом, BFGS строит аппроксимацию обратного гессиана самостоятельно. Результаты — в таблице 3, траектории — на рис. 3.

Таблица 3. Сходимость методов второго порядка

Метод	Функция	Итераций	$f(\vec{\theta}^*)$	$\vec{\theta}^*$
Ньютон (аналит. H)	Розенброк	23	$2.5 \cdot 10^{-28}$	$(1;\ 1)$
Ньютон (числ. H)	Розенброк	23	$3.0 \cdot 10^{-27}$	$(1;\ 1)$
BFGS	Розенброк	17	$4.3 \cdot 10^{-18}$	$(1;\ 1)$
Ньютон (аналит. H)	Химмельблау	5	$1.3 \cdot 10^{-22}$	$(-2.805;\ 3.131)$
Ньютон (числ. H)	Химмельблау	5	$1.3 \cdot 10^{-22}$	$(-2.805;\ 3.131)$
BFGS	Химмельблау	8	$2.2 \cdot 10^{-18}$	$(3.584;\ -1.848)$

Методы второго порядка заметно экономнее первого: Ньютон сходится за считанные итерации, его траектория практически не чувствует изогнутости долины Розенброка и скользит вдоль неё к точке $(1; 1)$, дав точность до 10^{-28}. Численный гессиан (якобиан численного градиента) даёт ту же траекторию и то же число итераций. BFGS на первых итерациях ведёт себя как наискорейший спуск ($B_0 = I$),

затем уточнение B_k позволяет ему развернуться вдоль долины и сойтись за 17 итераций — быстрее всех методов первого порядка. На Химмельблау методы из одной стартовой точки $(-4; 4)$ попадают в разные бассейны притяжения: Ньютон — в минимум $(-2.805;\ 3.131)$ всего за 5 итераций, BFGS — в $(3.584;\ -1.848)$ за 8 итераций, что ещё раз иллюстрирует многомодальность функции.

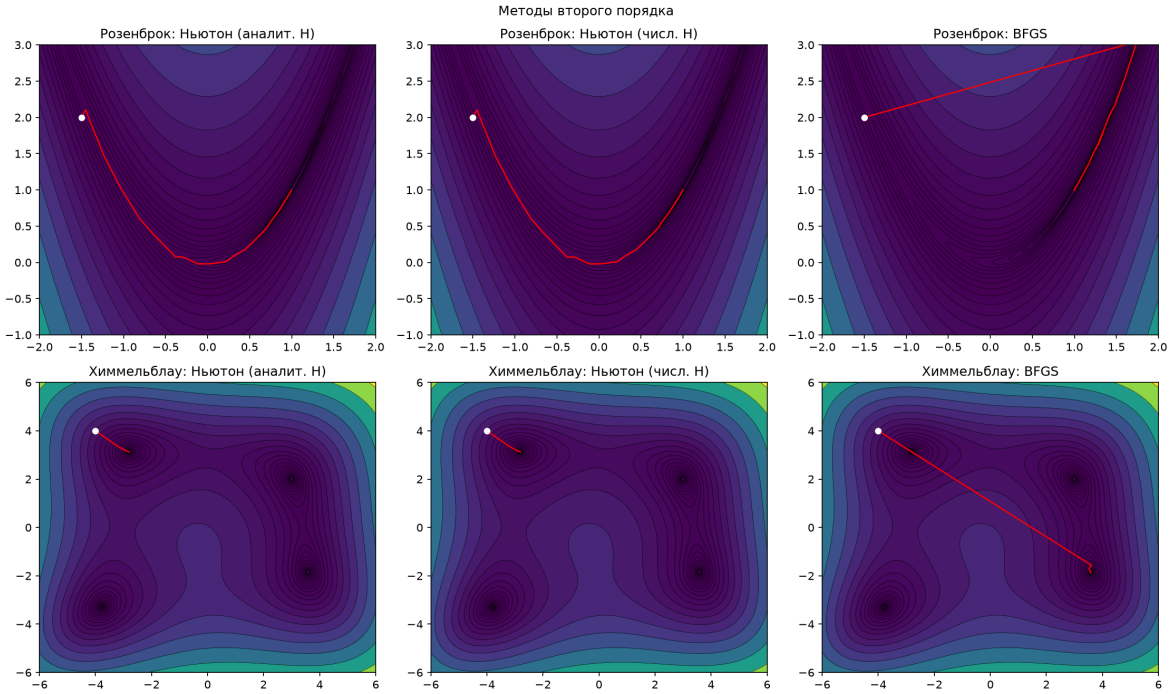


Рис. 3. Траектории методов второго порядка: Ньютон (аналитический и численный гессиан) и BFGS

3. Методы нулевого порядка

Нелдер–Мид. На двумерной функции Розенброка симплекс из трёх вершин стартует из точки $(-1{,}5; 2{,}0)$; на рис. 4 белыми линиями показано положение симплекса в характерные моменты, красной — траектория его центроида. Метод сперва стягивает симплекс и перетаскивает его по дну долины, затем ведёт к минимуму $(1; 1)$ за 128 итераций с $f \approx 5.2 \cdot 10^{-18}$. На шестимерной функции (старт $(-1, \dots, -1)^T$, рис. 5) наблюдается классическая для Розенброка картина: длительные плато медленного спуска (между 50-й и 450-й итерациями f убывает всего с 10^0 до 10^{-1}), после чего сходимость резко ускоряется и за ≈ 200 последних итераций невязка падает ниже 10^{-13}; всего потребовалось 673 итерации, $f^* \approx 1.2 \cdot 10^{-14}$.

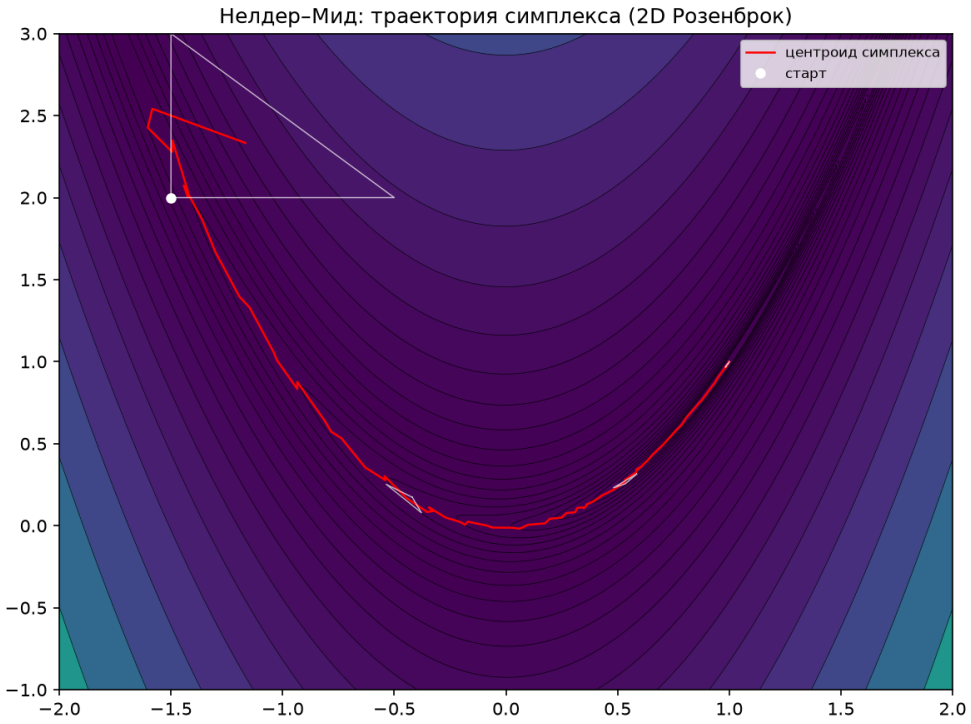


Рис. 4. Нелдер–Мид: траектория центроида и положение симплекса (2D Розенброк)

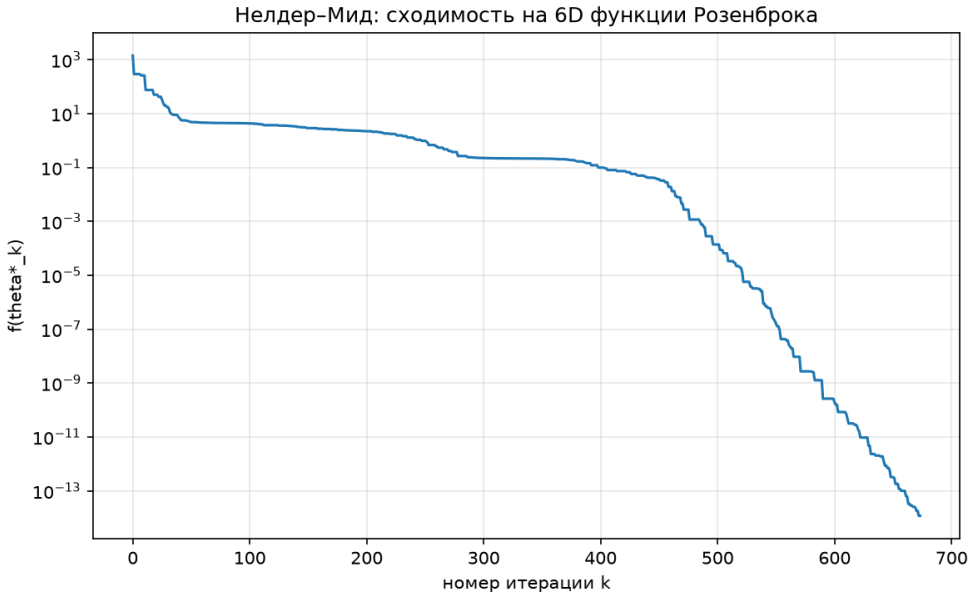


Рис. 5. Нелдер–Мид: сходимость $f(\vec{\theta}^{*_k})$ на шестимерной функции Розенброка

Рой частиц (PSO). Рой из 30 частиц минимизирует двумерную функцию Розенброка в области $[-2; 2] \times [-1; 3]$ в течение 150 итераций; на рис. 6 показаны позиции частиц и векторы их скоростей на итерациях 0, 50, 100 и 150. В начале частицы равномерно рассеяны по области (итерация 0); к 50-й итерации рой заметно концентрируется в долине, белая звезда — текущий глобальный лидер; к 100-й итерации большинство частиц локализовано в окрестности минимума, скорости ещё значимы; к 150-й итерации рой схлопывается в точке $(1; 1)$. Адаптивные коэффициенты обеспечивают баланс глобального поиска на старте и локальной сходимости в конце: вместе с убывающей инерцией они позволяют рою

пройти узкую долину и найти глобальный минимум с $f \approx 2.2 \cdot 10^{-10}$ в точке $(1.00000;\ 1.00000)$ без единого вычисления производных. Результаты блока сведены в таблицу 4.

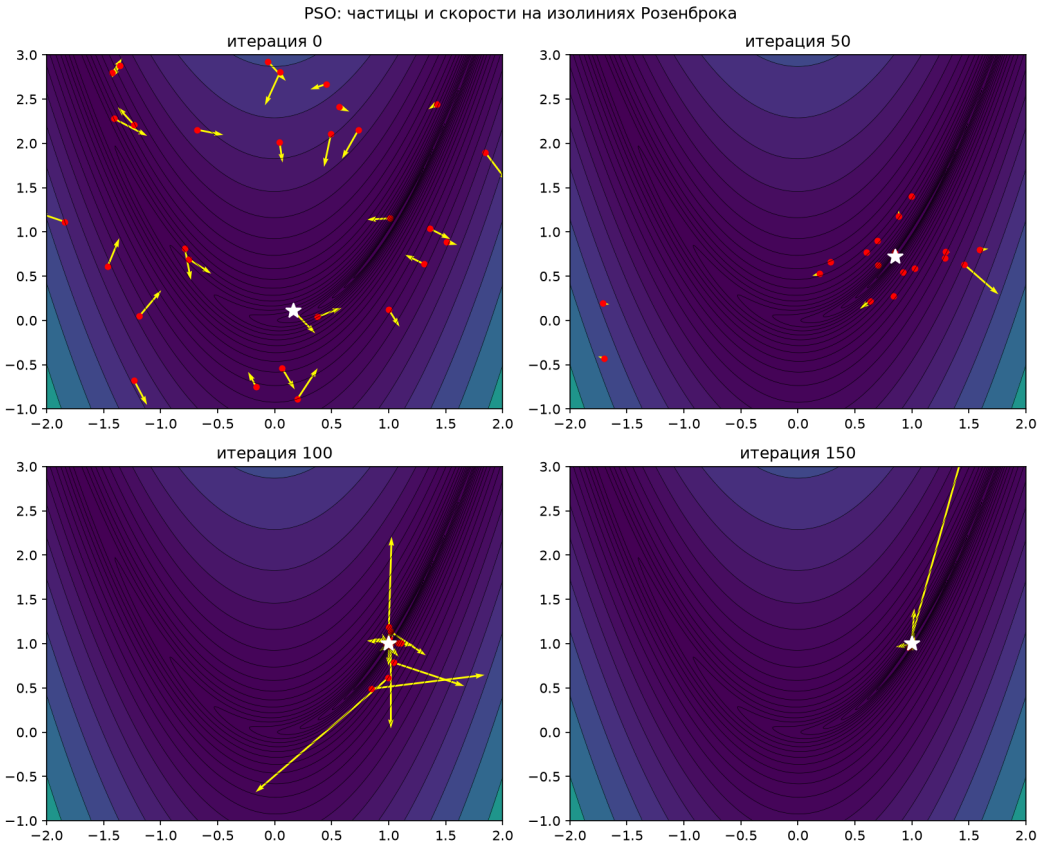


Рис. 6. PSO: распределение частиц и их скоростей на изолиниях Розенброка

Таблица 4. Результаты методов нулевого порядка

Метод	Задача	Итераций	$f(\vec{\theta}^*)$	$\vec{\theta}^*$
Нелдер–Мид	Розенброк 2D	128	$5.2 \cdot 10^{-18}$	$(1;\ 1)$
Нелдер–Мид	Розенброк 6D	673	$1.2 \cdot 10^{-14}$	$f(\theta^{*_k})$, рис. 5
PSO (30 частиц)	Розенброк 2D	150	$2.2 \cdot 10^{-10}$	$(1.00000;\ 1.00000)$

4. Нелинейный метод наименьших квадратов

Функция Розенброка записывается как задача МНК с невязками $r(\vec{\theta}) = (1 - \theta_1;\ 10(\theta_2 - \theta_1^2))^T$; оба метода стартуют из $(-1{,}5; 2{,}0)$. Результаты — в таблице 5, траектории и графики — на рис. 7. Оба метода проходят долину и сходятся к $(1; 1)$; Левенберг–Марквардт делает это плавнее за счёт демпфирования, Гаусс–Ньютон использует дробление шага.

В задаче аппроксимации генерируются $n = 40$ зашумлённых точек (x_i, y_i) истинной моделью

$$g_{\vec{\theta}}(x) = a\, e^{-((x-b)/c)^2} + d\, x$$

с параметрами $\vec{\theta}_{true} = (2{,}0;\ 1{,}5;\ 0{,}8;\ 0{,}3)^T$ и шумом $\xi \sim N(0; 0{,}05)$; невязки $r_i(\vec{\theta}) = g_{\vec{\theta}}(x_i) - y_i$, якобиан вычисляется конечными разностями. Нижний ряд рис. 7

показывает эволюцию кривой $g_{\vec{\theta}}(x)$ по итерациям Левенберга–Марквардта (начальная прямая сгибается в гауссову кривую и подгоняется под данные уже к 5-й итерации) и кривые сходимости невязки: оба метода снижают $S(\vec{\theta}_k)$ с ≈ 40 до $5.1 \cdot 10^{-2}$ — уровня, определяемого шумом данных. Левенберг–Марквардт сходится за 11 итераций, а Гаусс–Ньютон, чей полный шаг на старте далёк от минимума, работает до ограничения в 300 итераций, но приходит в ту же точку $\vec{\theta}^* \approx (1.966;\ 1.507;\ 0.811;\ 0.300)$, близкую к истинной. Результаты — в таблице 5.

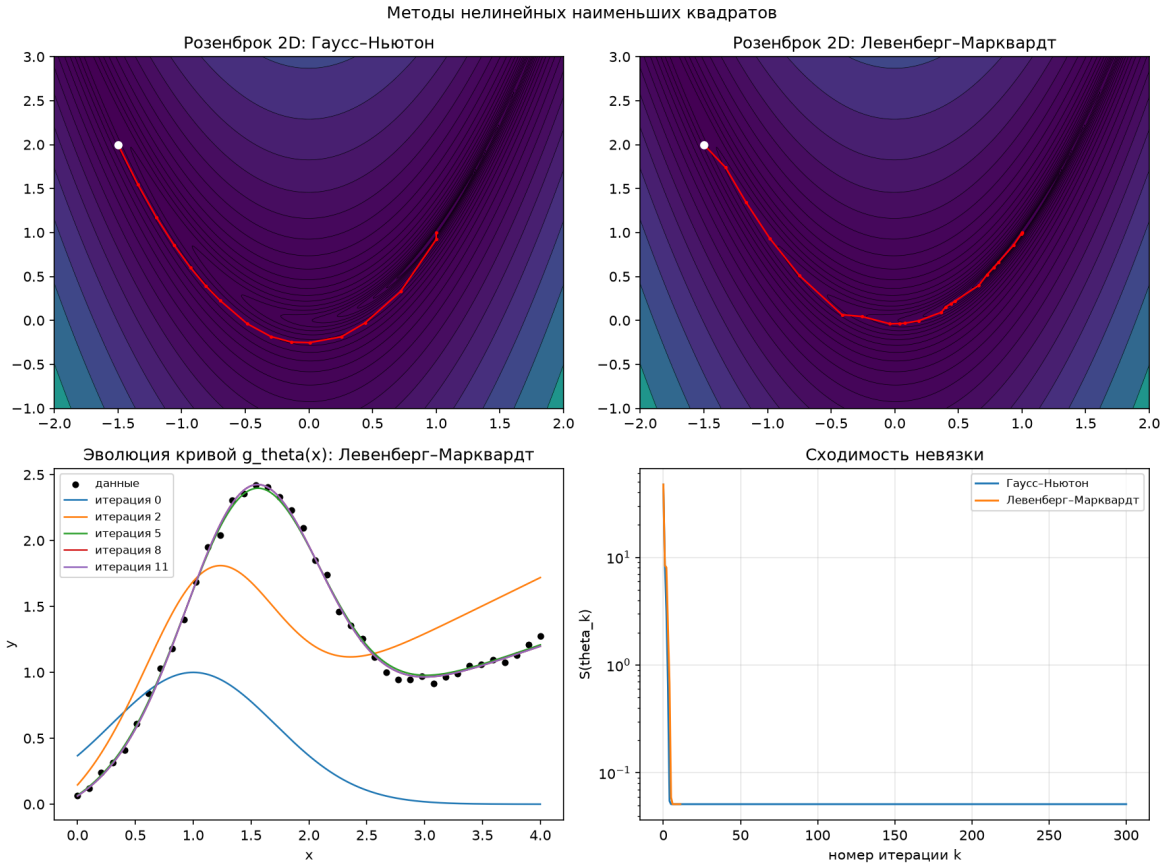


Рис. 7. МНК: траектории на Розенброке, эволюция кривой аппроксимации и сходимость невязки

Таблица 5. Результаты методов нелинейных наименьших квадратов

Метод	Задача	Итераций	$f(\vec{\theta}^*)$
Гаусс–Ньютон	Розенброк 2D	15	$5.0 \cdot 10^{-30}$
Левенберг–Марквардт	Розенброк 2D	23	$9.5 \cdot 10^{-24}$
Гаусс–Ньютон	аппроксимация данных	300 (предел)	$5.1 \cdot 10^{-2}$
Левенберг–Марквардт	аппроксимация данных	11	$5.1 \cdot 10^{-2}$

5. Распределение времени на сессию

Выполнено по $n = 100$ запусков обоих подходов со случайных начальных приближений $t_i \sim U(0{,}1; 8)$. Итоговые кластеры сошедшихся решений приведены в таблице 6.

Таблица 6. Мультизапуск (100 стартов): кластеры решений задачи распределения времени

Подход	$(t_1;\ t_2;\ t_3)$, ч	Траекторий	$F(\vec{t})$
Проекция на симплекс	$(6.01;\ 0.00;\ 1.99)$	69	-1.989
Проекция на симплекс	$(0.00;\ 6.06;\ 1.94)$	24	-1.966
Проекция на симплекс	$(2.95;\ 5.05;\ 0.00)$	7	-1.301
Квадратичный штраф (BFGS)	$(6.01;\ 0.00;\ 1.99)$	75	-1.989
Квадратичный штраф (BFGS)	$(0.00;\ 6.06;\ 1.94)$	25	-1.966

Мультизапуск показывает, что задача многомодальна: оба метода находят два близких по качеству решения, а доминирующим (69–75 траекторий из 100) является точка $(6.01;\ 0;\ 1.99)$ с $F \approx -1.989$. Физический смысл результата таков: почти всё время отдаётся первому экзамену, чья логистическая кривая при $t_1 \approx 6$ практически насыщается ($P_1 \approx 0.99$), и третьему — ровно столько, чтобы встать в пик его гауссианы ($t_3 \approx 2$, $P_3 \approx 1$). Второму экзамену время не выделяется: его сигмоида центрирована при $t_{02} = 4{,}5$, поэтому при $t_2 = 0$ вероятность почти нулевая ($P_2 \approx 10^{-4}$), а подъём её до заметных значений потребовал бы слишком большой доли бюджета. Проверка предельных выигрышей подтверждает оптимум: в точке решения производные $\partial P_1/\partial t_1 \approx 0.016$ и $\partial P_3/\partial t_3 \approx 0.013$ выровнены, тогда как $\partial P_2/\partial t_2 \approx 2.5 \cdot 10^{-4}$ — почти в 60 раз меньше.

Второй кластер $(0;\ 6.06;\ 1.94)$ соответствует альтернативной стратегии «спасти второй экзамен»: часть вероятности первого жертвуется ради частичного насыщения второго, итоговая суммарная вероятность чуть ниже (-1.966). Метод проекции из 100 стартов семь раз попал ещё и в худший локальный минимум $(2.95;\ 5.05;\ 0)$ с $F = -1.301$ (делёж времени между первым и вторым экзаменами без учёта третьего); штрафной метод с теми же стартами в него не попал. Доминирующие кластеры обоих подходов совпадают почти полностью (69 против 75 траекторий), а значения F согласованы с точностью до тысячных, что подтверждает эквивалентность проекции и штрафного метода, несмотря на принципиально разные механизмы учёта ограничений.

Вывод

В лабораторной работе реализован единый программный комплекс численной оптимизации на языке Python с модульной архитектурой: базовый класс `TargetFunction` с аналитическим и конечно-разностным дифференцированием, базовый класс `Optimizer` с единообразным накоплением истории и метрик сходимости, класс `LineSearch` (золотое сечение) для одномерного поиска шага, а также самостоятельные модули для методов нулевого порядка, нелинейных наименьших квадратов и задачи с ограничениями.

Реализовано и протестировано пятнадцать методов: градиентные первого порядка (наискорейший спуск, его вариант с фиксированным шагом, покомпонентный спуск в двух вариантах обхода и с фиксированным шагом, момент Нестерова, Adam, Adagrad, RMSProp), второго порядка (Ньютон, BFGS), нулевого порядка (Нелдер–Мид, PSO с адаптивными коэффициентами), методы Гаусса–Ньютона и Левенберга–Марквардта, а также два способа учёта ограничений — проекция на симплекс и квадратичная штрафная функция.

Вычислительные эксперименты на функциях Розенброка и Химмельблау показали: сравнение аналитического и численного дифференцирования подтвердило корректность обеих схем (траектории практически совпадают); спуск с фиксированным шагом уступает наискорейшему по надёжности и сильно зависит от обусловленности задачи, а адаптивные методы (Adam, Adagrad, RMSProp) проходят изогнутую долину Розенброка без одномерного поиска — каждый со своими особенностями: у Adagrad затухает шаг, у RMSProp с постоянным lr устанавливается блуждание окрестности минимума; методы второго порядка сходятся за считанные итерации, но требуют гессиана или его аппроксимации; безпроизводные методы успешно работают в многомерном случае (Нелдер–Мид на 6-мерной Розенброке), а PSO с адаптивной инерцией и весами находит глобальный минимум без вычисления производных. Методы МНК уверенно решают как минимизацию Розенброка, так и аппроксимацию зашумлённых данных четырёхпараметрической моделью, снижая невязку до уровня шума.

В прикладной задаче распределения времени на сессию оба подхода к ограничениям (проекция на симплекс и квадратичный штраф) при мультизапуске из 100 случайных точек сходятся к согласованному решению $(6.01;\ 0;\ 1.99)$ часов с суммарной вероятностью сдачи ≈ 1.99, рационально распределяющему бюджет $M = 8$ часов между экзаменами и подтверждающему устойчивость найденного оптимума.